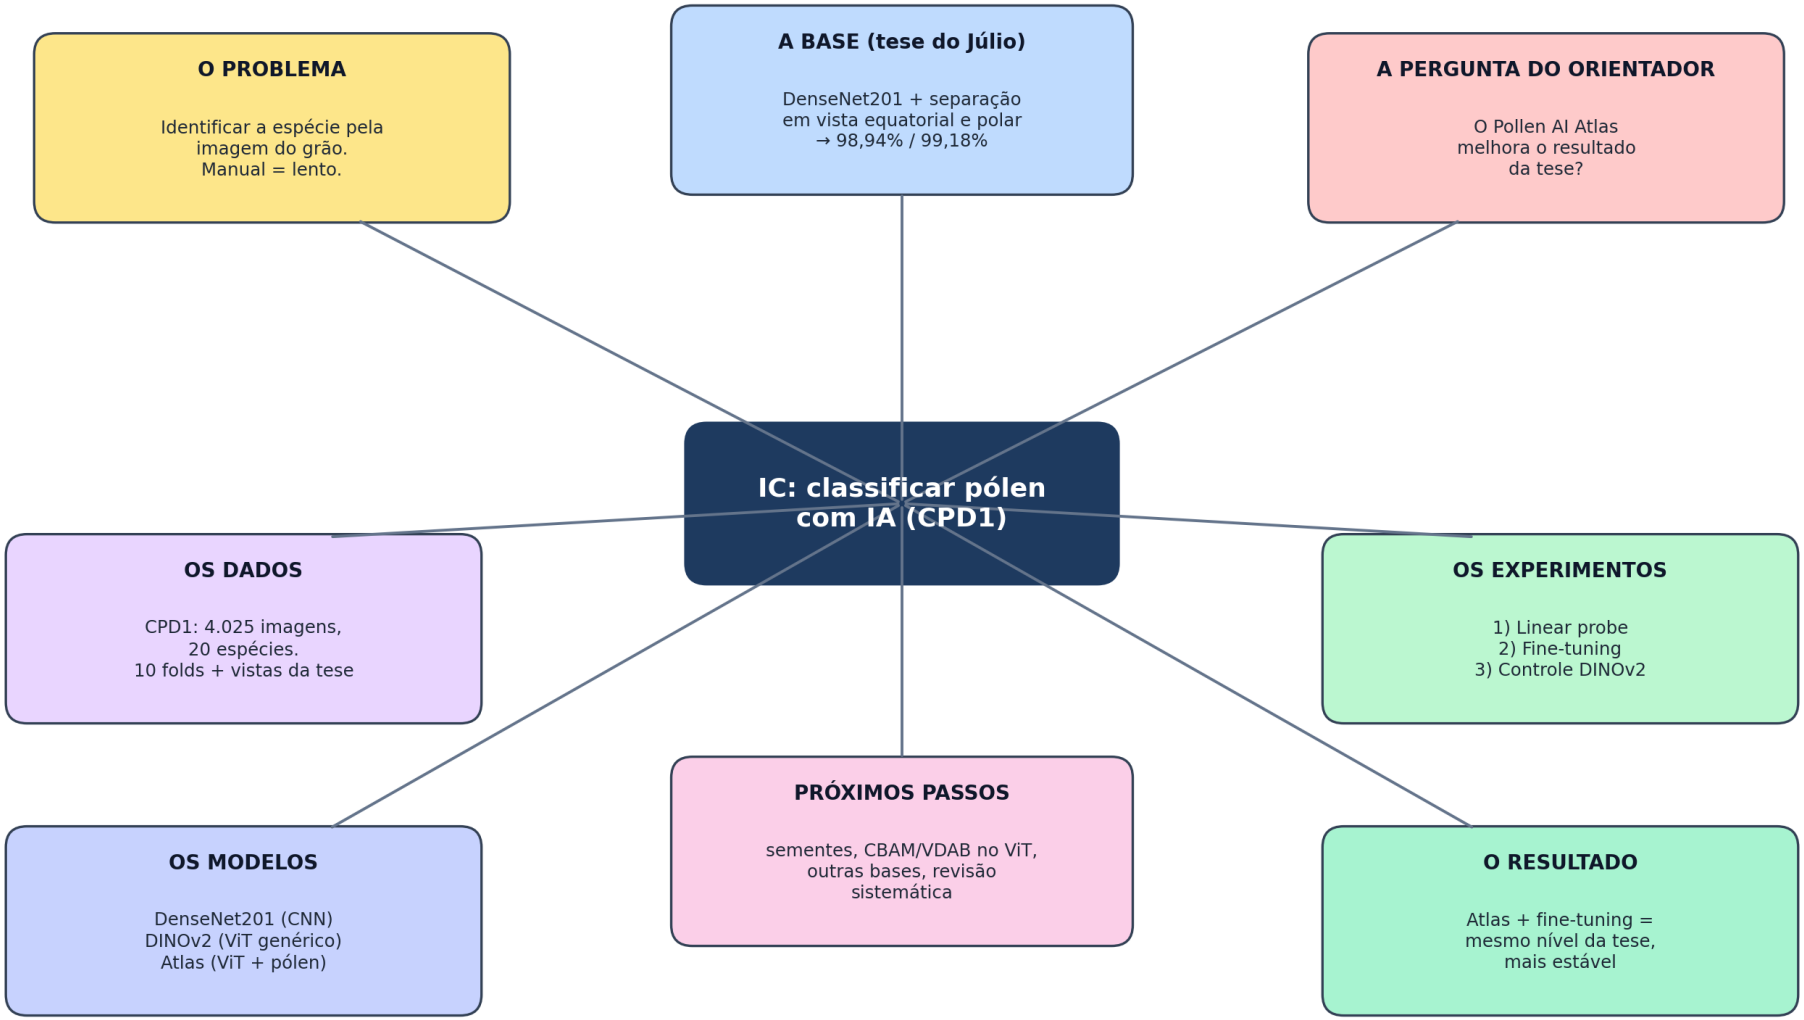
O projeto em um mapa

comece por aqui

Cada caixa é um tema deste guia. A ideia central: **testar se um modelo pré-treinado com 1,5 milhão de grãos de pólen (o Pollen AI Atlas) consegue igualar ou superar a DenseNet201 da tese do Júlio**, usando exatamente os mesmos dados e a mesma avaliação.



As peças do quebra-cabeça

glossário com analogias

Rede neural

Um programa que **aprende com exemplos**: vê milhares de imagens com a resposta certa e ajusta seus "botões" internos (os **pesos**) até acertar. *Analogia: um aluno que treina com uma lista de exercícios resolvidos.*

CNN (DenseNet201)

Rede que olha a imagem por **pedacinhos vizinhos** e vai montando a figura camada por camada. É o modelo da tese do Júlio. *Analogia: ler um texto palavra por palavra.*

ViT (Vision Transformer)

Rede que corta a imagem em **pedaços** e compara **todos com todos** ao mesmo tempo ("atenção"). Enxerga bem a forma global. *Analogia: olhar a página inteira de uma vez.*

DINOv2

Um ViT da Meta pré-treinado em **142 milhões de imagens gerais** (gatos, carros, paisagens), sem rótulos. Sabe "ver" muito bem, mas nunca estudou pólen. *Analogia: um médico generalista bem formado.*

Pollen AI Atlas

O **DINOv2 que estudou pólen**: o grupo do Biricz ajustou ele com 1,5 milhão de grãos e publicou os pesos (o arquivo **.pth**). *Analogia: o mesmo médico, depois de uma residência em palinologia.*

Backbone × cabeça

Backbone: a parte que extrai as características da imagem (o "olho"). **Cabeça**: a última camada, que decide a espécie. Do Atlas usamos o backbone e trocamos a cabeça (46 espécies europeias → 20 do CPD1).

Embedding

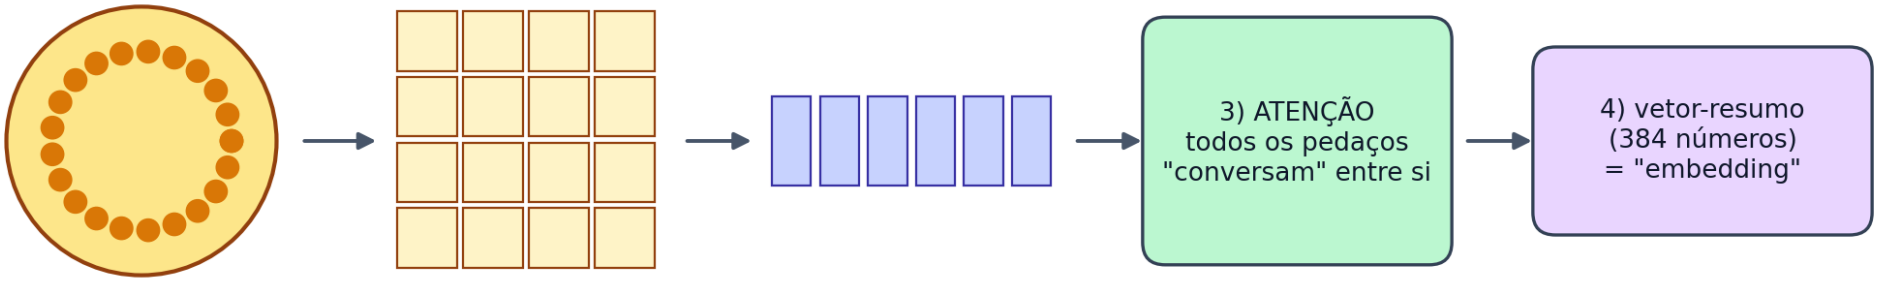
O **resumo numérico** que o backbone faz de uma imagem: no ViT-S, uma lista de **384 números**. Imagens parecidas geram listas parecidas. *Analogia: a "impressão digital" do grão.*

Foundation model

Modelo treinado antes, em muitos dados, para ser **reaproveitado**. Em vez de começar do zero, partimos de quem já sabe ver. *Analogia: contratar alguém experiente em vez de um iniciante.*

Como o ViT enxerga — e o que o Atlas tem de especial

Como um Vision Transformer (ViT) enxerga uma imagem



Diferença para a CNN (DenseNet201): a CNN olha pedacinhos vizinhos e vai juntando camada por camada; o ViT compara todos os pedaços com todos desde o início — por isso entende bem a forma global do grão.

DINOv2 × Atlas: mesma arquitetura

Os dois são um **ViT-S/14** ("S" de small, pedaços de 14 pixels). A única diferença está nos **pesos**: o Atlas continuou o treino do DINOv2 com imagens de pólen.

O Atlas mudou mesmo?

No notebook, comparamos os pesos dos dois: a maior diferença foi **0,00227**. Não é zero, então o Atlas **foi de fato ajustado com pólen** — mas de forma sutil (o treino deles usou uma taxa de aprendizado pequena).

Por que isso importa

Se os pesos fossem iguais, comparar Atlas e DINOv2 não faria sentido. Como são diferentes, a comparação **mede o efeito do pré-treino em pólen** — essa é a pergunta do controle.

Os dados: CPD1, vistas e folds

CPD1 (Cretan Pollen Dataset)

Fotos de grãos de **20 espécies** da ilha de Creta, já recortadas (um grão por imagem). Depois do pré-processamento do Júlio: **4.025 imagens** de 224×224 pixels.

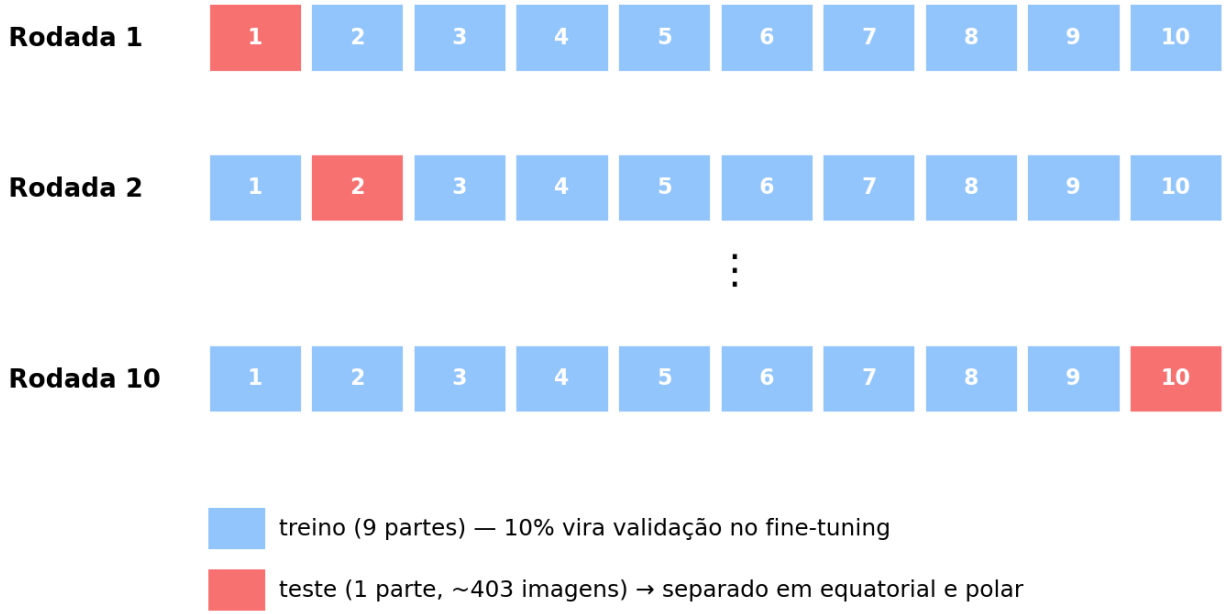
Vista equatorial × polar

O mesmo grão parece diferente conforme a posição: visto **de lado** (equatorial, mostra aberturas e forma alongada) ou **de cima** (polar, mais arredondado e simétrico). Na base: **2.110 equatoriais e 1.915 polares**.

De onde vieram as vistas

O link da base separada deu erro 404. Achamos no repositório **Pollen-Classification-CBAM** a lista de cada imagem de teste com seu fold e sua vista — e reconstruímos tudo, idêntico à tese.

Validação cruzada em 10 folds (como na tese)

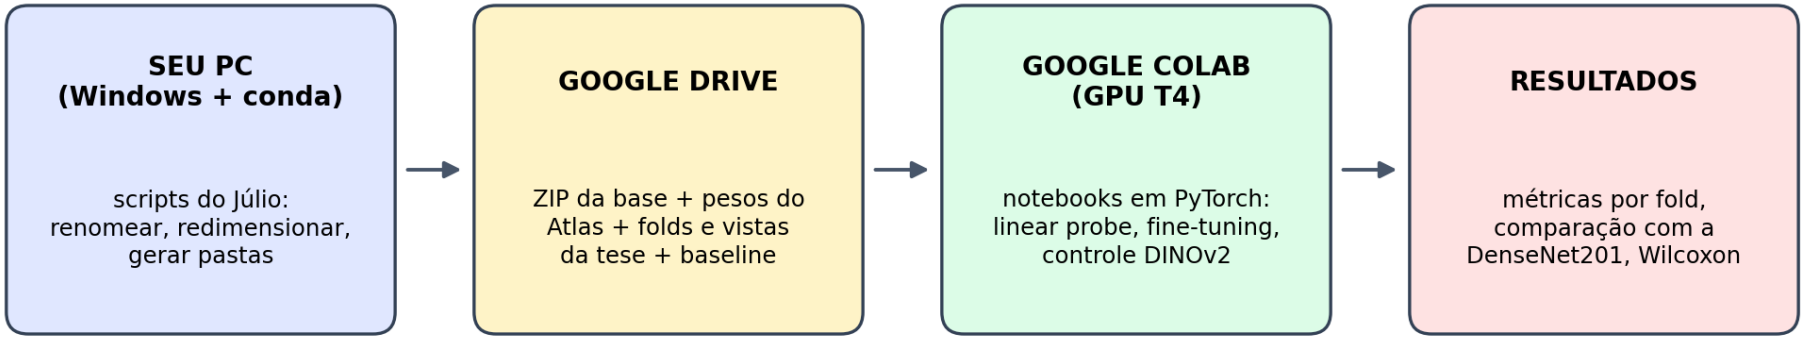


Por que importa

- toda imagem é testada exatamente uma vez
- o resultado é a MÉDIA das 10 rodadas (± desvio)
- usamos os MESMOS folds do Júlio → comparação justa, fold a fold

A integração passo a passo

Como os dois pipelines foram integrados



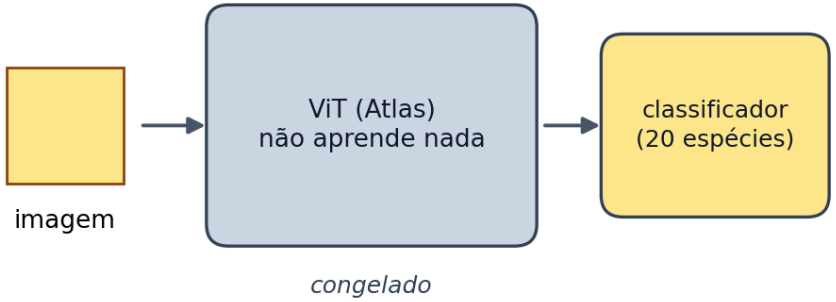
Os folds e as vistas vieram do repositório Pollen-Classification-CBAM (results/phase3/CPD1_TEST_VIEW): assim o Atlas foi testado exatamente nas mesmas imagens que a DenseNet201 da tese.

Os obstáculos que apareceram — e como resolvemos

Problema	Por que aconteceu	Solução
tensorflow-addons não instalou	a versão 0.23 não existe para Windows	instalamos só as bibliotecas do pré-processamento (não precisa de TensorFlow)
No module named 'models'	o Python não sabia onde estava o código do Júlio	set PYTHONPATH=%cd% antes de rodar os scripts
Cópia das imagens falhou	o código separava caminhos com "/" (Linux); o Windows usa "\"	troquei 2 linhas por os.path.basename / dirname
Link da base com vistas: erro 404	o arquivo saiu do Google Drive do Júlio	reconstruímos as vistas pelas listas de resultados do repositório com CBAM
Folds diferentes dos da tese	Windows e Linux listam os arquivos em ordens diferentes	usamos os folds exatos do Júlio, das mesmas listas
Imagens aug_ podiam "colar"	foram geradas a partir dos SEUS folds, não dos da tese	não usamos; o aumento de dados é feito na hora, no treino
Cota de GPU do Colab acabou	limite do plano gratuito	os resultados são salvos fold a fold; é só retomar depois

Os três experimentos

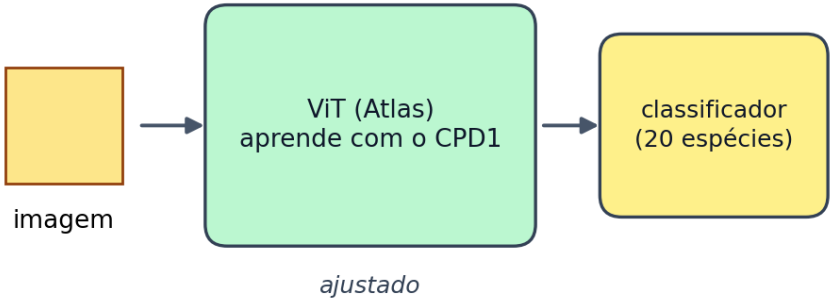
Experimento 1 — LINEAR PROBE



Só o classificador final aprende.
Rápido e barato — mede o que o modelo já "sabe" sem estudar o CPD1.

Resultado: ~96–97% (abaixo da tese)

Experimento 2 — FINE-TUNING



O modelo inteiro aprende, devagar.
Mais lento — é como a DenseNet201 foi treinada na tese.

Resultado: ~99% (empatou com a tese)

1) Linear probe: teste-surpresa

O Atlas responde sem estudar o CPD1. Mostra quanto ele já sabe sobre pólen. Resultado: **bom (≈97%), mas abaixo da tese**.

2) Fine-tuning: estudar p/ a prova

O Atlas estuda o CPD1 inteiro, como a DenseNet201 estudou. Resultado: **empatou com a tese** (98,76% / 99,38%) e foi **mais estável**.

3) Controle: e sem a residência?

O mesmo estudo, mas partindo do **DINOv2 genérico**. Se ele fosse igual ao Atlas, o pólen não teria ajudado. Resultado: o Atlas foi **melhor** (+0,43 ponto), **com significância na vista polar**.

Painel de resultados

médias dos 10 folds

Atlas + fine-tuning

equatorial	polar
98,76%	**99,38%**

DenseNet201 (tese)

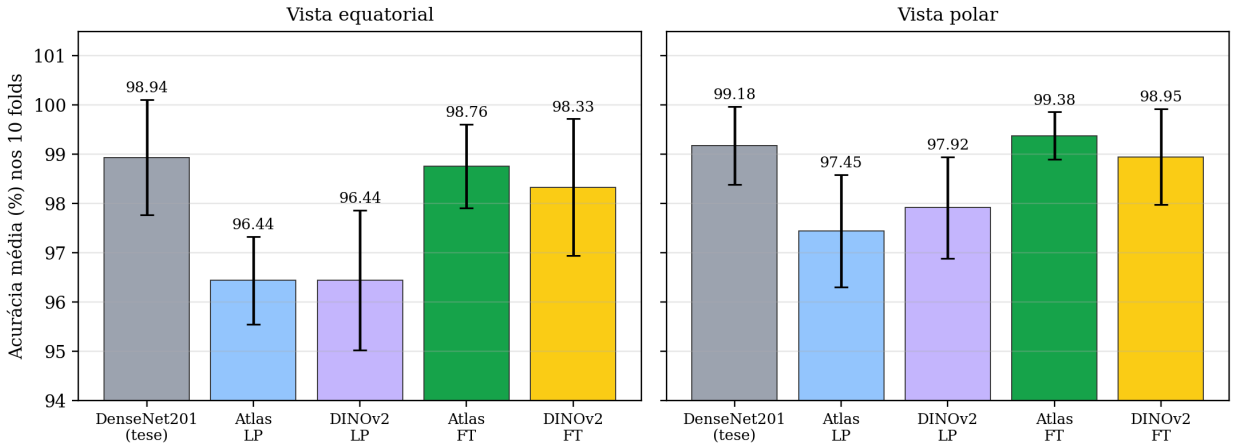
equatorial	polar
98,94%	**99,18%**

DINOv2 + fine-tuning

equatorial	polar
98,33%	**98,95%**

Atlas + linear probe

equatorial	polar
96,44%	**97,45%**



O que o teste de Wilcoxon disse

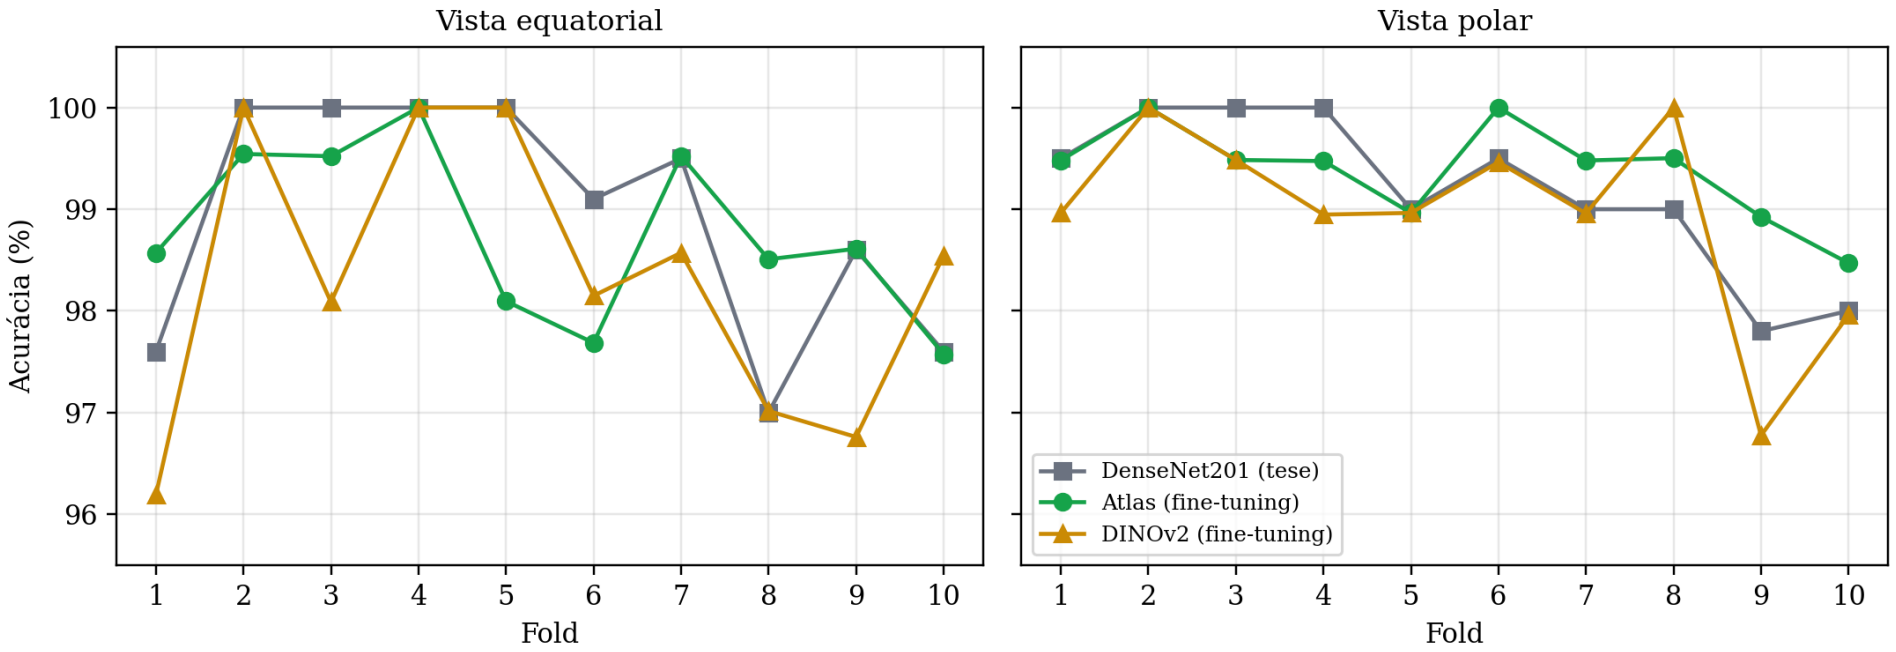
Comparação	Equatorial	Polar
Atlas (FT) × DenseNet201	sem diferença	sem diferença
DINOv2 (FT) × DenseNet201	sem diferença	no limite (p=0,055)
Atlas (FT) × DINOv2 (FT)	Atlas +0,43 (n.s.)	Atlas melhor ✓
Atlas: FT × linear probe	FT melhor ✓	FT melhor ✓
Linear probe × DenseNet201	tese melhor	tese melhor

Verde-claro: estatisticamente igual · **verde**: diferença significativa a favor · **amarelo**: vantagem sem significância ou no limite · **vermelho**: a tese foi melhor.

Em uma frase: congelado, o Atlas não alcança a tese; **estudando o CPD1 (fine-tuning), ele empata com a DenseNet201, varia menos entre os folds e supera o DINOv2 genérico na vista polar** — sinal de que o pré-treino em pólen ajuda. E a vista polar foi a mais fácil para todos os modelos, como na tese.

Olhando fold a fold

A média esconde detalhes. Aqui está cada um dos 10 folds do fine-tuning, com a DenseNet201 da tese como referência.



Placar Atlas × tese (por fold)

Polar: 5 vitórias, 3 empates, 2 derrotas.
Equatorial: 2 vitórias, 4 empates, 4 derrotas.
(Empate = diferença de até 0,05 ponto, por causa do arredondamento dos resultados da tese.)

Por que o Atlas é mais estável

Nos folds em que a DenseNet201 caiu — o **8** na equatorial e os **9 e 10** na polar —, o Atlas **se manteve acima de 98,4%**. Ele raramente tem um fold ruim: por isso o desvio padrão dele é o menor.

DINOv2: muita oscilação

Por que ele não foi **significativamente** pior na equatorial? O DINOv2 genérico oscila muito: **96,19% no fold 1** e **100% nos folds 2, 4 e 5**. Com tanta variação, 10 folds não bastam para o teste afirmar a diferença — mesmo com o Atlas 0,43 ponto à frente na média.

Como ler os números — e como explicar ao orientador

Média ± desvio

98,76 ± 0,85 quer dizer: na média dos 10 folds, 98,76% de acerto; e os folds variaram, tipicamente, uns 0,85 ponto para cima ou para baixo. **Desvio menor = modelo mais estável**, menos dependente de quais imagens caíram no teste.

Pontos percentuais (pp)

Diferença entre duas porcentagens. De 98,33% para 98,76% são **+0,43 pp**. Parece pouco, mas perto de 99% sobra pouco para melhorar: é quase **um quarto a menos de erros**.

Valor-p (Wilcoxon)

A chance de ver uma diferença assim **se os modelos fossem iguais**. Abaixo de **0,05** = diferença significativa. Cuidado: **"não significativo" não prova que são iguais**; diz só que, com 10 folds, não deu para ver diferença.

Roteiro de 1 minuto para o orientador

1. Integrei o Pollen AI Atlas ao pipeline do Júlio **com os mesmos 10 folds e as mesmas vistas da tese**.
2. Congelado (linear probe), ele chega a ~97%: **abaixo da DenseNet201**, com diferença significativa.
3. Com fine-tuning completo, chega a **98,76% (equatorial) e 99,38% (polar)**: estatisticamente igual à tese, com menor variação.
4. No controle, o DINOv2 genérico ficou **0,43 ponto abaixo** do Atlas — significativo na vista polar. Ou seja, **o pré-treino em pólen ajuda**.
5. Próximos passos: várias sementes, ajuste de hiperparâmetros, CBAM/VDAB no ViT e outras bases.

Perguntas que ele pode fazer

"Por que não superou a tese?" Os hiperparâmetros não foram otimizados e cada fold rodou uma vez só; mesmo assim empatou.
"A comparação é justa?" Mesmos folds, mesmas imagens de teste e mesmas métricas; o treino é que foi diferente.
"Como sabe que o pólen ajudou?" Pelo controle: mesma rede, mesmo treino, só muda o pré-treino.
"Por que as imagens aug_ não foram usadas?" Vieram de outra divisão de folds e podiam vazar imagens de teste.
"Dá para reproduzir?" Sim: notebooks, folds e pesos estão salvos; os resultados ficam no Drive.