Integração do Pollen AI Atlas ao Pipeline de Classificação de Grãos de Pólen por Vistas: Linear Probe, Fine-tuning e Controle com DINOv2

Monnik Luianne Oliveira Nascimento Veloso Barbosa[1], Kelson Rômulo Teixeira Aires[1]

[1]Departamento de Computação – Universidade Federal do Piauí (UFPI)
Teresina – PI – Brasil

monnik.barbosa@ufpi.edu.br

Abstract. *This report evaluates whether the Pollen AI Atlas, a Vision Transformer (ViT-S/14, DINOv2) adapted with 1.5 million pollen grains, can be integrated into the view-based pollen classification pipeline of Soares et al. (2025). Using exactly the ten folds and the equatorial/polar test split of that thesis on the Cretan Pollen Dataset (CPD1), we compared a linear probe, full fine-tuning and a generic DINOv2 control against the reported DenseNet201. Linear probing reached 96.44% (equatorial) and 97.45% (polar), significantly below the DenseNet201 (Wilcoxon, $p \leq 0.004$). Full fine-tuning of the Atlas reached 98.76% and 99.38%, statistically indistinguishable from the DenseNet201 (98.94% and 99.18%) and with lower variance across folds. The generic DINOv2 under the same fine-tuning reached 98.33% and 98.95%; the Atlas pollen pre-training was significantly better on the polar view ($p = 0.031$).*

Resumo. *Este relatório avalia se o Pollen AI Atlas, um Vision Transformer (ViT-S/14, DINOv2) ajustado com 1,5 milhão de grãos de pólen, pode ser integrado ao pipeline de classificação de pólen por vistas de Soares et al. (2025). Usando exatamente os dez folds e a separação do teste em vistas equatorial e polar dessa tese no Cretan Pollen Dataset (CPD1), comparamos linear probe, fine-tuning completo e um controle com o DINOv2 genérico contra a DenseNet201 da tese. O linear probe atingiu 96,44% (equatorial) e 97,45% (polar), significativamente abaixo da DenseNet201 (Wilcoxon, $p \leq 0{,}004$). O fine-tuning completo do Atlas atingiu 98,76% e 99,38%, estatisticamente indistinguível da DenseNet201 (98,94% e 99,18%) e com menor variação entre folds. O DINOv2 genérico com o mesmo fine-tuning atingiu 98,33% e 98,95%; o pré-treino em pólen do Atlas foi significativamente melhor na vista polar ($p = 0{,}031$).*

1. Introdução

A identificação de grãos de pólen ao microscópio é a base da palinologia e tem aplicações diretas na melissopalinologia (determinação da origem botânica do mel), na aerobiologia e no monitoramento ambiental. Feita manualmente, é lenta e depende de especialistas, o que motiva o uso de visão computacional e aprendizado profundo para automatizar a tarefa.

Soares et al. (2025) propuseram um pipeline em que as imagens do teste são separadas, por pseudo-rotulação, em **vista equatorial** e **vista polar** antes da avaliação, mostrando que a classificação por vista revela diferenças de desempenho importantes. No Cretan Pollen Dataset (CPD1), a DenseNet201 desse trabalho alcançou, segundo os

resultados por fold disponibilizados pelos autores, 98,94% de acurácia média na vista equatorial e 99,18% na polar.

Em paralelo, surgiram os *foundation models*: redes pré-treinadas em quantidades muito grandes de imagens, que podem ser adaptadas a tarefas específicas com poucos dados. O Pollen AI Atlas [Biricz et al. 2026] ajustou um Vision Transformer da família DINOv2 com cerca de 1,5 milhão de grãos de pólen e disponibilizou os pesos publicamente. A pergunta deste trabalho, proposta pela orientação da iniciação científica, é: **integrar o Pollen AI Atlas ao pipeline de vistas melhora os resultados obtidos na tese?**

Os objetivos foram: (i) integrar os pesos do Atlas ao protocolo da tese, com os mesmos folds e a mesma separação por vistas; (ii) avaliar o modelo congelado (*linear probe*) e com ajuste completo (*fine-tuning*); e (iii) isolar o efeito do pré-treino em pólen com um controle usando o DINOv2 genérico.

2. Trabalhos Relacionados

O CPD1 foi apresentado por Tsiknakis et al. (2022), que também propuseram um ensemble de redes com transferência de aprendizado. Mahmood et al. (2023) propuseram a APFA-Net, uma CNN leve com atenção por canal (*Squeeze-and-Excitation*), avaliada no CPD1 com validação em dois folds. Zolfaghari e Sajedi (2024) apresentaram a RCANet, que combina uma ResNet18 com um bloco de atenção inspirado nas vias visuais ventral e dorsal (VDAB), relatando 98,71% de acurácia no CPD1. Soares et al. (2025) introduziram a separação por vistas com pseudo-rotulação e, em versão posterior do código, mecanismos de atenção CBAM [Woo et al. 2018].

Os Vision Transformers [Dosovitskiy et al. 2021] dividem a imagem em pequenos blocos (*patches*) e os processam com mecanismos de atenção. O DINOv2 [Oquab et al. 2024] é uma família de ViTs pré-treinados de forma auto-supervisionada em 142 milhões de imagens, cujas representações funcionam bem sem ajuste. O Pollen AI Atlas [Biricz et al. 2026] partiu do DINOv2 e o ajustou com grãos de pólen de quatro origens europeias. Até onde sabemos, este é o primeiro teste desse modelo no protocolo de vistas do CPD1.

3. Materiais e Métodos

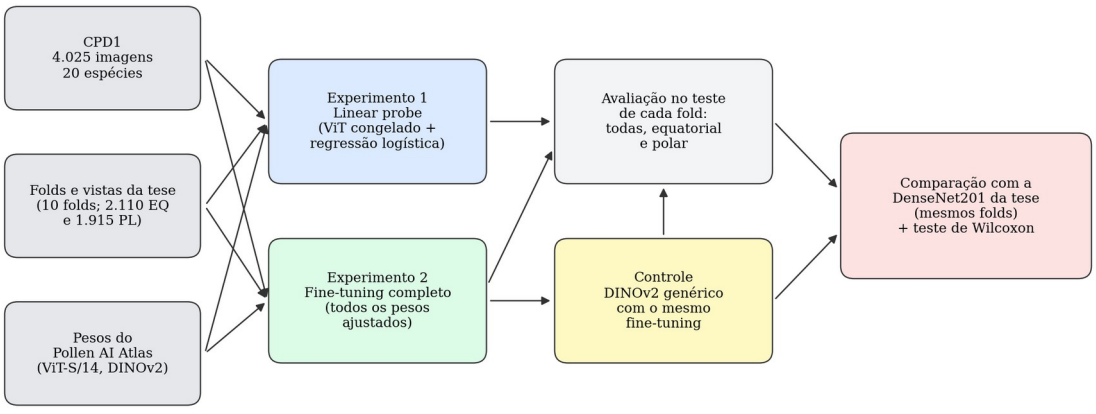


Figura 1. Visão geral da metodologia: dados, experimentos e comparação com a tese.

3.1. Base de dados

Foi usado o CPD1 [Tsiknakis et al. 2022], com imagens recortadas de grãos de 20 espécies da ilha de Creta. Após o pré-processamento do pipeline de Soares et al. (2025) —

renomeação das pastas e redimensionamento para 224 × 224 pixels —, a base ficou com 4.025 imagens.

3.2. Folds e vistas da tese

Para a comparação ser justa, os experimentos usaram **exatamente os dez folds da tese**. A base com as vistas separadas, disponibilizada originalmente pelos autores, não estava mais acessível (erro 404), e gerar os folds novamente não reproduziria a divisão original: o script cria a lista de imagens na ordem em que o sistema operacional devolve os arquivos, que difere entre Linux e Windows. A solução foi reconstruir os folds e as vistas a partir dos resultados publicados no repositório Pollen-Classification-CBAM (pasta results/phase3/CPD1_TEST_VIEW), que listam cada imagem de teste com seu fold e sua vista.

A reconstrução cobriu as 4.025 imagens, cada uma em um único fold e em uma única vista: 2.110 equatoriais e 1.915 polares, com 402 ou 403 imagens de teste por fold. Seguindo o protocolo da tese, em cada fold o modelo é treinado com todas as imagens dos outros nove folds e o teste é separado em vistas apenas na avaliação.

3.3. Modelos

DenseNet201 (referência). Os resultados por fold da DenseNet201 foram retirados do mesmo repositório da tese, sem novo treinamento.

Pollen AI Atlas. Foi usado o checkpoint público weights_vit_small_lvd_20250620_0312.pth, um ViT-S/14 da família DINOv2. Antes dos experimentos, os pesos foram comparados com os do DINOv2 original: a maior diferença absoluta foi de $2{,}27 \times 10^{-3}$, confirmando que o *backbone* foi de fato ajustado com pólen. A camada de saída do Atlas (46 táxons europeus) foi descartada.

DINOv2 genérico. Mesma arquitetura (vit_small_patch14_dinov2.lvd142m), com os pesos originais, sem o ajuste em pólen.

3.4. Experimento 1: linear probe

O ViT permanece congelado e transforma cada imagem em um vetor de 384 valores. Uma regressão logística (com padronização das variáveis) é treinada sobre esses vetores. As imagens foram redimensionadas para 518 × 518 pixels, resolução usada no treino do Atlas, e normalizadas com as estatísticas do ImageNet. O objetivo era medir quanta informação útil sobre pólen as representações prontas carregam, com custo computacional baixo.

3.5. Experimento 2: fine-tuning completo

Todos os pesos do ViT são ajustados com o CPD1, com uma nova camada de saída de 20 classes. As escolhas de treino estão na Tabela 1. Em cada fold, 10% do treino (estratificado por espécie) foi reservado para validação, usada para escolher a melhor época e para a parada antecipada; o teste só foi usado uma vez, ao final.

O aumento de dados foi feito durante o treino, com as mesmas transformações do pipeline da tese (rotação de até 25°, translação, espelhamentos, desfoque, brilho e contraste), e o balanceamento entre espécies foi feito por sorteio ponderado. As imagens aumentadas geradas localmente pelo script da tese **não** foram usadas, pois tinham sido criadas a partir de outra divisão de folds e poderiam carregar informação de imagens de teste para o treino.

Tabela 1. Configuração do fine-tuning (Experimento 2 e controle).

Parâmetro	Valor
Resolução de entrada	224 × 224 (tamanho nativo da base)
Otimizador	AdamW, weight decay 0,05
Taxa de aprendizado	2×10^{-5} (backbone) e 1×10^{-3} (camada de saída)
Agendamento	One-cycle, 10% de aquecimento
Épocas	até 20, parada antecipada com paciência 5
Lote / precisão	32 imagens / mista (fp16)
Função de perda	entropia cruzada com label smoothing 0,1
Validação	10% do treino, estratificada
Semente	42 + número do fold

3.6. Controle com DINOv2 genérico

O controle repete o Experimento 2 com a mesma configuração, os mesmos folds e as mesmas sementes, mudando apenas o ponto de partida: os pesos genéricos do DINOv2. Assim, a diferença entre o Atlas e o controle isola o efeito do pré-treino em pólen.

3.7. Métricas e análise estatística

Foram calculadas acurácia, precisão, revocação e F1 com média ponderada por classe, e o índice kappa de Cohen, as mesmas métricas dos relatórios da tese. As comparações usam o teste de postos sinalizados de Wilcoxon [Wilcoxon 1945], pareado por fold (n = 10), com nível de significância de 5%.

3.8. Ambiente e integração

A preparação dos dados usou os scripts da tese em ambiente Conda com Python 3.10.13 no Windows. Foram necessárias três adaptações: instalar apenas as dependências do pré-processamento (o pacote tensorflow-addons 0.23 não tem versão para Windows e não é usado nessa etapa), definir o PYTHONPATH para o projeto e corrigir, em models/split_BD_Views_k.py, a separação de caminhos feita com "/", que falhava no Windows. Os experimentos rodaram no Google Colab (GPU Tesla T4) com PyTorch e a biblioteca timm [Wightman 2019]; cada fold de fine-tuning levou entre 3,4 e 6,7 minutos (média de 4,9 minutos para o Atlas e 4,7 para o DINOv2).

4. Resultados

4.1. Experimento 1 — primeiro fold

O primeiro fold serviu para validar a integração. A Tabela 2 mostra que o linear probe ficou entre 96% e 98%, abaixo da DenseNet201 nas duas vistas.

Tabela 2. Acurácia (%) no fold 1 do Experimento 1.

Modelo	Todas	Equatorial	Polar
DenseNet201 (tese)	—	97,60	99,50
Atlas (linear probe)	96,53	96,19	96,89
DINOv2 (linear probe)	97,27	96,67	97,93

4.2. Experimento 1 — dez folds

Nos dez folds (Tabela 3 e Figura 2), o linear probe ficou abaixo da DenseNet201 em quase todos os folds. As diferenças médias foram de −2,50 pontos percentuais na vista equatorial para os dois ViTs e de −1,73 (Atlas) e −1,26 (DINOv2) na polar, todas significativas ($p \leq 0{,}004$; Tabela 5). Na vista equatorial, Atlas e DINOv2 empataram na média (96,44%), mas o Atlas variou menos entre os folds (desvio de 0,89 contra 1,42).

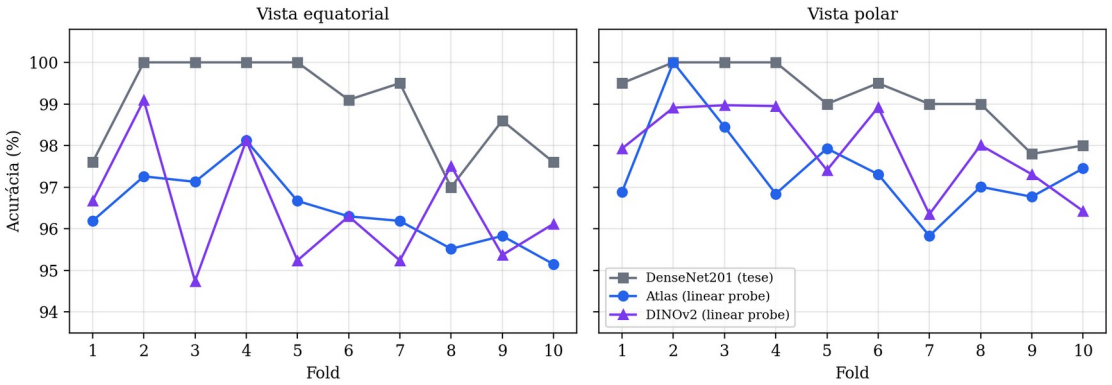


Figura 2. Acurácia por fold no Experimento 1, comparada à DenseNet201 da tese.

4.3. Experimento 2 — primeiro fold

O treino do Atlas no fold 1 foi estável (Figura 3): a acurácia de validação subiu de 88,7% na primeira época para 99,7% na oitava, e o treino parou na 13ª época por não haver melhora. No teste, o Atlas obteve 98,57% na vista equatorial (contra 97,60% da DenseNet201) e 99,48% na polar (contra 99,50%).

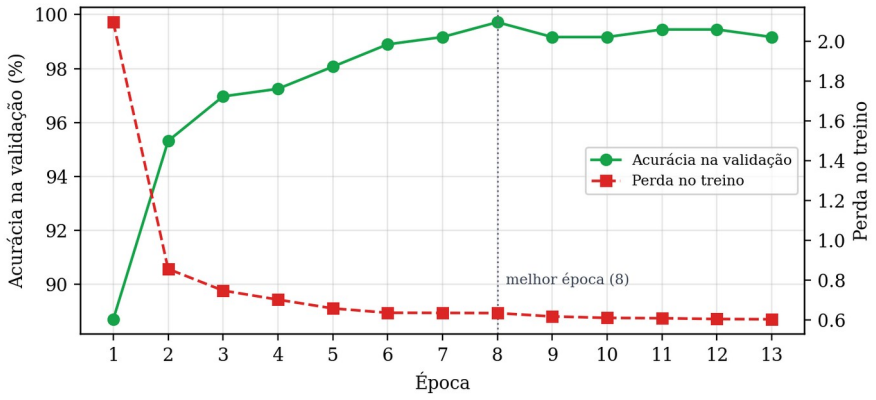


Figura 3. Curva de treino do Atlas no fold 1 (fine-tuning).

4.4. Experimento 2 — dez folds e controle

A Tabela 3 e a Figura 4 resumem todos os modelos. Com fine-tuning, o Atlas atingiu 98,76% (equatorial) e 99,38% (polar), sem diferença significativa em relação à DenseNet201 ($p = 0{,}59$ e $p = 0{,}66$), e com desvio padrão menor nas duas vistas. O ganho em relação ao próprio linear probe foi de +2,33 e +1,93 pontos, ambos significativos.

O controle com o DINOv2 genérico atingiu 98,33% e 98,95%, também sem diferença significativa em relação à DenseNet201, embora no limite na vista polar ($p = 0{,}055$). Na comparação direta, o Atlas superou o DINOv2 em +0,43 ponto nas duas vistas; a diferença foi significativa na polar ($p = 0{,}031$) e não significativa na equatorial ($p = 0{,}46$), onde o DINOv2 variou bastante entre os folds.

Tabela 3. Resultados médios (%) nos dez folds: acurácia ± desvio padrão, F1 e kappa.

Modelo	Acc. EQ	F1 EQ	κ EQ	Acc. PL	F1 PL	κ PL
DenseNet201 (tese)	98,94 ± 1,17	98,98	98,70	99,18 ± 0,79	99,13	98,94
Atlas (linear probe)	96,44 ± 0,89	96,48	95,66	97,45 ± 1,14	97,51	96,75
DINOv2 (linear probe)	96,44 ± 1,42	96,47	95,66	97,92 ± 1,03	98,03	97,35
Atlas (fine-tuning)	98,76 ± 0,85	98,77	98,49	99,38 ± 0,48	99,38	99,21
DINOv2 (fine-tuning)	98,33 ± 1,39	98,37	97,96	98,95 ± 0,97	98,98	98,66

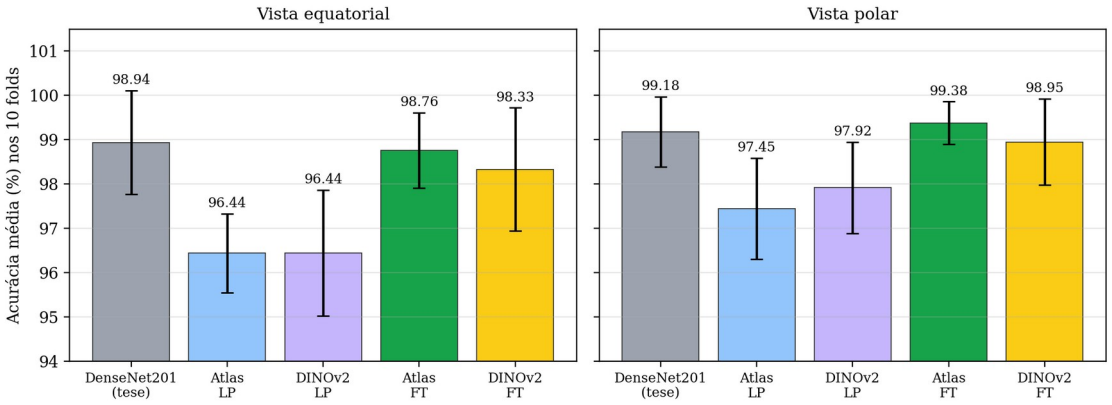


Figura 4. Acurácia média e desvio padrão nos dez folds, por vista. LP: linear probe; FT: fine-tuning.

A Figura 5 mostra o fine-tuning fold a fold. Na vista polar, o Atlas superou a DenseNet201 em cinco folds, empatou em três e ficou abaixo em dois; na equatorial, ficou acima em dois, empatou em quatro e abaixo em quatro (considerando empate diferenças de até 0,05 ponto, por causa do arredondamento dos resultados da tese). O padrão mais relevante está nos folds mais difíceis para a DenseNet201 — o fold 8 na vista equatorial e os folds 9 e 10 na polar —, nos quais o Atlas manteve acurácia acima de 98,4%. Isso explica seu desvio padrão menor. O DINOv2 genérico teve as maiores quedas (96,19% no fold 1 da vista equatorial e 96,77% no fold 9 da polar), o que eleva sua variância e ajuda a entender por que a vantagem do Atlas não foi significativa na vista equatorial.

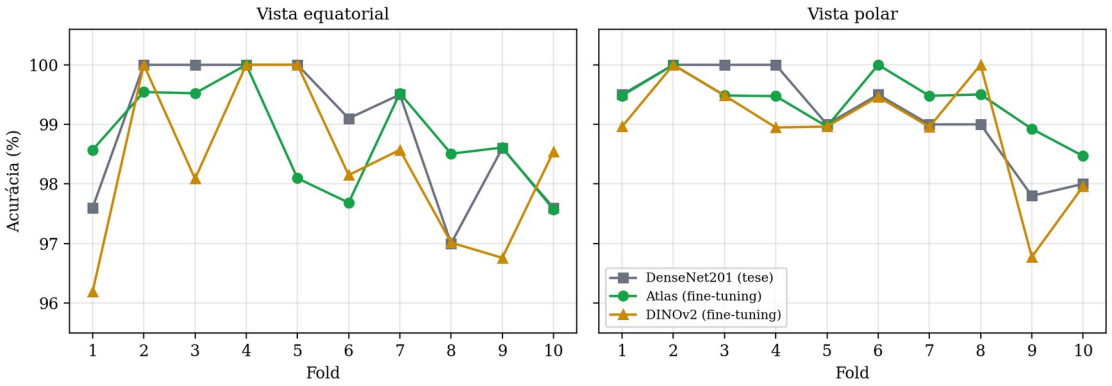


Figura 5. Acurácia por fold no Experimento 2 (fine-tuning), comparada à DenseNet201 da tese.

Tabela 4. Acurácia média (%) no teste completo, sem separar vistas.

Modelo	Acurácia	F1	Kappa
Atlas (linear probe)	96,92 ± 0,82	96,91	96,56
DINOv2 (linear probe)	97,14 ± 1,06	97,14	96,81
Atlas (fine-tuning)	99,06 ± 0,57	99,05	98,95
DINOv2 (fine-tuning)	98,63 ± 0,96	98,62	98,47

A DenseNet201 não aparece na Tabela 4 porque o repositório da tese traz os resultados por fold apenas por vista.

Tabela 5. Teste de Wilcoxon pareado por fold (n = 10) sobre a acurácia.

Etapa	Comparação	Dif. EQ (pp)	p EQ	Dif. PL (pp)	p PL
Exp. 1	Atlas (LP) × DenseNet201	−2,50	0,0020	−1,73	0,0039
Exp. 1	DINOv2 (LP) × DenseNet201	−2,50	0,0039	−1,26	0,0020
Exp. 2	Atlas (FT) × DenseNet201	−0,18	0,5898	+0,20	0,6602
Exp. 2	Atlas (FT) × Atlas (LP)	+2,33	0,0020	+1,93	0,0039
Controle	DINOv2 (FT) × DenseNet201	−0,61	0,1562	−0,23	0,0547
Controle	DINOv2 (FT) × DINOv2 (LP)	+1,89	0,0098	+1,03	0,0156
Controle	Atlas (FT) × DINOv2 (FT)	+0,43	0,4609	+0,43	0,0312

Valores de p abaixo de 0,05 indicam diferença significativa. Dif.: diferença média de acurácia, em pontos percentuais.

5. Discussão

O fine-tuning foi decisivo. As representações prontas do ViT já classificam o CPD1 acima de 96%, mas ficam significativamente abaixo de uma CNN treinada inteiramente no domínio. Ao ajustar todos os pesos, os dois ViTs alcançaram o nível da DenseNet201. Isso mostra que um modelo de outra família (Transformer em vez de CNN) consegue atingir o estado da arte no protocolo de vistas da tese.

O pré-treino em pólen ajudou, de forma moderada. O Atlas superou o DINOv2 genérico nas duas vistas e de forma significativa na polar, além de apresentar menor variação entre folds em todos os cenários. O ganho é pequeno em valor absoluto, o que é coerente com dois fatores: as espécies do Atlas vêm do centro e do norte da Europa, enquanto as do CPD1 são mediterrâneas; e, com acurácias acima de 98%, resta pouca margem para diferenças.

A vista polar foi a mais fácil para todos os modelos. O padrão observado na tese com a DenseNet201 se repetiu nos ViTs, com e sem fine-tuning, reforçando que a separação por vistas capta uma característica real da morfologia dos grãos, e não uma particularidade de uma arquitetura.

5.1. Limitações

A configuração de treino não foi idêntica à da DenseNet201: hiperparâmetros, aumento de dados e balanceamento foram próprios deste trabalho e não foram otimizados. Os resultados da DenseNet201 foram reaproveitados do repositório, e não reexecutados no mesmo ambiente. Cada fold foi treinado uma única vez, com uma semente. Com apenas dez pares, o teste de Wilcoxon tem baixo poder: "não significativo" indica que não houve evidência de diferença, e não que os modelos sejam comprovadamente equivalentes — para isso seria necessário um teste de equivalência. Por fim, o linear probe usou resolução de 518 pixels e o fine-tuning, de 224, o que deve ser considerado ao comparar os dois experimentos.

6. Conclusão e Trabalhos Futuros

A integração do Pollen AI Atlas ao pipeline de vistas da tese foi viável e reprodutível. Congelado, o modelo não supera a DenseNet201; com fine-tuning completo, atinge desempenho estatisticamente equivalente ao da tese (98,76% na vista equatorial e 99,38% na polar), com menor variação entre folds. O controle com o DINOv2 genérico indica que o pré-treino em pólen contribui para esse resultado, de forma significativa na vista polar.

Como próximos passos, propõe-se: repetir os treinos com várias sementes e aplicar um teste de equivalência; ajustar os hiperparâmetros e testar resoluções maiores e backbones maiores (ViT-B); incorporar mecanismos de atenção como CBAM e VDAB ao ViT; avaliar as bases POLLEN23E e POLLEN73S, cujos resultados por vista também estão no repositório da tese; analisar mapas de atenção para interpretar as decisões do modelo; e conduzir uma revisão sistemática sobre aprendizado profundo para classificação de pólen.

Referências

Biricz, B. et al. (2026). Million-scale multimodal pollen microscopy with expert-guided foundation models. *arXiv preprint* arXiv:2606.17809.

Dosovitskiy, A. et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*.

Huang, G., Liu, Z., van der Maaten, L. e Weinberger, K. Q. (2017). Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 4700–4708.

Loshchilov, I. e Hutter, F. (2019). Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*.

Mahmood, T., Choi, J. e Park, K. R. (2023). Artificial intelligence-based classification of pollen grains using attention-guided pollen features aggregation network. *Journal of King Saud University – Computer and Information Sciences*, 35(2).

Oquab, M. et al. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*.

Soares, J. C. d. S., Aires, K. R. T., Bendini, J. d. N., Brandão, W. V. B. e Veras, R. d. M. S. (2025). Enhanced pollen classification via hybrid neural network with attention

mechanism and view separation: An equatorial and polar approach. *IEEE Access*, 13:77365–77381.

Tsiknakis, N. et al. (2022). Pollen grain classification based on ensemble transfer learning on the Cretan Pollen Dataset. *Plants*, 11(7):919.

Wightman, R. (2019). PyTorch Image Models (timm). GitHub, https://github.com/huggingface/pytorch-image-models.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.

Woo, S., Park, J., Lee, J.-Y. e Kweon, I. S. (2018). CBAM: Convolutional block attention module. In *European Conference on Computer Vision (ECCV)*, p. 3–19.

Zolfaghari, M. e Sajedi, H. (2024). Automated classification of pollen grains microscopic images using cognitive attention based on human Two Visual Streams Hypothesis. *PLOS ONE*, 19(11):e0309674.